دانشکده ریاضی و کامپیوتر
بخش علوم کامپیوتر

گزارش پروژه کارشناسی

عنوان پروژه:
طراحی سامانه هوشمند پایش سلامت تجهیزات صنعتی مبتنی بر یادگیری عمیق و سیستم استنتاج فازی

دانشجو: **محمد رضا غلامی**
استاد راهنما: **دکتر مرجان کوچکی رفسنجانی**

سال تحصیلی ۱۴۰۴-۱۴۰۵

چکیده

خرابی تجهیزات صنعتی، به ویژه یاتاقان‌ها (بلبرینگ‌ها)، یکی از عوامل اصلی توقف‌های ناخواسته خطوط تولید، افزایش هزینه‌های نگهداری و کاهش بهره وری در صنایع معدنی است . تشخیص به موقع عیوب و ارزیابی وضعیت سلامت تجهیزات، نقش مهمی در برنامه ریزی مناسب فعالیت‌های تعمیراتی و جلوگیری از گسترش خرابی‌ها دارد . با این حال ، بسیاری از سامانه‌های موجود تنها به تشخیص نوع خرابی محدود بوده و اطلاعات کافی برای پشتیبانی از تصمیم‌گیری کارشناسان تعمیرات ارائه نمی‌دهند.

در این پروژه، یک سامانه هوشمند هیبریدی مبتنی بر یادگیری عمیق و سیستم استنتاج فازی طراحی و پیاده‌سازی شده است . در فاز نخست، با استفاده از داده‌های ارتعاشی یاتاقان (دیتاست استاندارد CWRU با نرخ نمونه برداری ۴۸ کیلوهرتز)، نوع خرابی توسط یک شبکه عصبی کانولوشنی (CNN) با معماری سه بلوکه شناسایی می‌شود. مدل نهایی به دقت ۹۶,۸۵٪ (و پیک ۹۷,۱۷٪) دست یافته است. سپس خروجی Softmax مدل همراه با وزن‌های شدت خرابی وارد یک سیستم استنتاج فازی از نوع ممدانی می‌شود تا شاخص سلامت (Health Index)، شدت خرابی (Severity) و سطح ریسک (Risk Level) محاسبه گردد.

نتایج تحلیل در قالب یک داشبورد تعاملی Streamlit نمایش داده می‌شود تا کارشناسان بتوانند وضعیت تجهیزات را به‌صورت ساده، قابل تفسیر و اولویت‌بندی‌شده مشاهده کرده و از پیشنهاد اولیه سامانه برای اقدام تعمیراتی بهره ببرند. معماری سامانه به‌گونه‌ای طراحی شده که قابلیت توسعه برای سایر تجهیزات صنعتی را نیز داشته باشد.

کلمات کلیدی: تشخیص عیب یاتاقان، شبکه عصبی کانولوشنی (CNN)، سیستم استنتاج فازی، شاخص سلامت، داشبورد تصمیم‌یار

۱. مقدمه

۱.۱. بیان مسئله

تجهیزات صنعتی از مهم‌ترین دارایی‌های خطوط تولید در صنایع معدنی محسوب می‌شوند و عملکرد صحیح آن‌ها نقش مستقیمی در تداوم تولید، کاهش هزینه‌های عملیاتی و افزایش قابلیت اطمینان فرآیندها دارد . خرابی ناگهانی تجهیزات، به‌ویژه اجزای دوار مانند یاتاقان‌ها، می‌تواند منجر به توقف‌های طولانی‌مدت، خسارات مالی قابل توجه و حتی خطرات ایمنی شود .

در بسیاری از واحدهای صنعتی ، ارزیابی وضعیت تجهیزات هنوز بر پایه بازرسی‌های دوره‌ای ، تحلیل دستی سیگنال‌های ارتعاشی و تجربه کارشناسان انجام می‌شود . این روش‌ها اگرچه مفید هستند ، اما با محدودیت‌هایی مانند تأخیر در تشخیص ، وابستگی به تخصص فردی و عدم ارائه شاخص‌های کمی و قابل تفسیر برای تصمیم‌گیری مواجه هستند .

طی سال‌های اخیر، استفاده از روش‌های مبتنی بر یادگیری عمیق در تحلیل داده‌های ارتعاشی، دقت تشخیص عیوب را به‌طور چشمگیری افزایش داده است . با این وجود، اکثر مدل‌های یادگیری عمیق تنها برچسب کلاس خرابی را تولید می‌کنند و خروجی آن‌ها برای کارشناسان نگهداری به‌صورت مستقیم قابل تفسیر و قابل استفاده در فرآیند تصمیم‌گیری تعمیراتی نیست . این شکاف بین «تشخیص دقیق» و «پشتیبانی عملی از تصمیم» انگیزه اصلی طراحی سامانه هیبریدی حاضر بوده است .

۱.۲. اهمیت موضوع

در صنایع معدنی مانند شرکت ملی صنایع مس ایران (مجتمع مس سرچشمه)، قابلیت اطمینان تجهیزات نقش تعیین‌کننده‌ای در تداوم فرآیند تولید و کنترل هزینه‌های نگهداری دارد . توقف‌های برنامه‌ریزی نشده ناشی از خرابی یاتاقان‌ها می‌تواند باعث کاهش تولید ، افزایش هزینه‌های تعمیرات اضطراری و کاهش عمر مفید تجهیزات شود .

طرح حاضر با هدف توسعه یک سامانه هوشمند پایش سلامت و تصمیم‌یار نگهداری تجهیزات ، تلاش می‌کند علاوه بر تشخیص نوع خرابی ، شاخص‌های قابل تفسیر مانند شاخص سلامت ، شدت خرابی و سطح ریسک را نیز در اختیار کارشناسان قرار دهد . این رویکرد می‌تواند زمینه بهبود برنامه ریزی تعمیرات ، کاهش توقف‌های ناخواسته و افزایش قابلیت اطمینان تجهیزات را فراهم آورد.

۱.۳. هدف پروژه

هدف اصلی این پروژه، طراحی و پیاده‌سازی یک سامانه هیبریدی است که با ترکیب شبکه عصبی کانولوشنی برای تشخیص نوع عیب یاتاقان و سیستم استنتاج فازی برای تبدیل خروجی مدل به شاخص‌های قابل تفسیر، امکان پایش هوشمند سلامت تجهیزات و پشتیبانی از تصمیم‌گیری تعمیراتی را فراهم کند . اهداف جزئی عبارتند از:

- طراحی و آموزش یک مدل CNN سبک و دقیق برای طبقه‌بندی ۱۰ کلاس وضعیت یاتاقان بر اساس داده‌های ارتعاشی CWRU
- توسعه سیستم استنتاج فازی ممدانی برای محاسبه Risk Level ، Health Index و Urgency
- پیاده‌سازی تابع پیش‌بینی بلادرنگ و داشبورد تعاملی Streamlit برای نمایش نتایج و پیشنهاد اقدام
- ارائه معماری توسعه پذیر که قابلیت تعمیم به سایر تجهیزات را داشته باشد

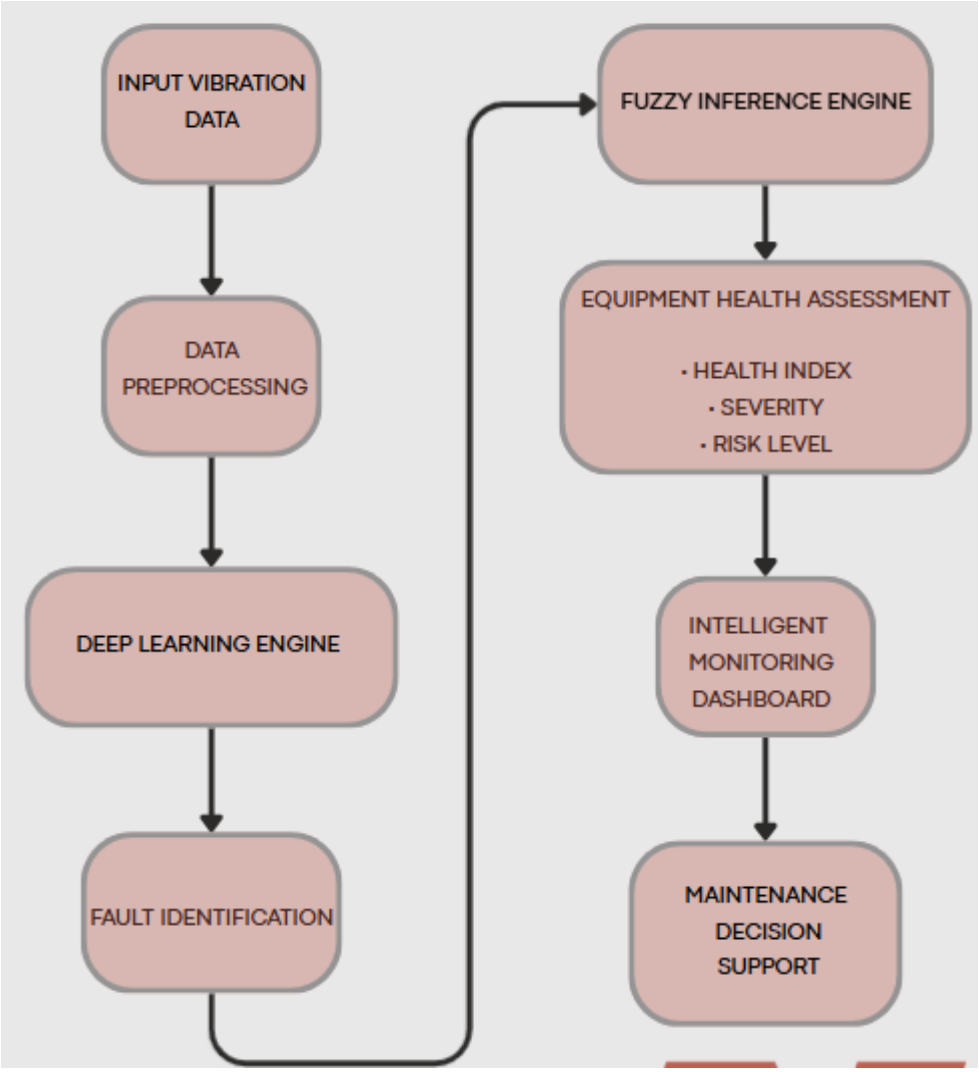
۲. روش پیشنهادی

۲.۱. معماری کلی سامانه

سامانه پیشنهادی از چهار بخش اصلی تشکیل شده است: (۱) دریافت و پیش‌پردازش داده ارتعاشی ، (۲) موتور یادگیری عمیق مبتنی بر CNN برای شناسایی نوع خرابی ، (۳) سیستم استنتاج فازی برای محاسبه شاخص‌های سلامت و ریسک ، و (۴) داشبورد هوشمند پایش و پشتیبانی تصمیم .

جریان داده به صورت زیر است:

سیگنال ارتعاشی ← پیش‌پردازش و تبدیل به تصویر ۳۲×۳۲ ← CNN (تشخیص نوع عیب + Softmax) ← محاسبه Health Index ← سیستم فازی (Risk Level / Urgency) ← نمایش در داشبورد.



شکل ۱ : معماری کلی سامانه پیشنهادی

۲.۲. دیتاست و پیش‌پردازش

در این پروژه از دیتاست استاندارد Case Western Reserve University (CWRU) با نرخ نمونه برداری ۴۸ کیلوهرتز استفاده شده است . این دیتاست شامل ۱۰ کلاس وضعیت یاتاقان است:

- Normal (سالم)
- Ball_007، Ball_014، Ball_021 (خرابی ساچمه با قطر های مختلف)
- IR_007، IR_014، IR_021 (خرابی حلقه داخلی)
- OR_007، OR_014، OR_021 (خرابی حلقه خارجی)

هر پنجره سیگنال به صورت جداگانه با روش z-score نرمال سازی شد و سپس به تصویر ۳۲×۳۲ تبدیل گردید . داده‌ها به صورت لایه بندی شده (stratified) با نسبت ۸۰٪ آموزش و ۲۰٪ آزمون تقسیم شدند . تعداد کل نمونه‌ها حدود ۴۶۰۰ نمونه است.

۲.۳. معماری شبکه عصبی کانولوشنی (CNN)

مدل CNN طراحی شده شامل سه بلوک کانولوشنی متوالی و یک بخش طبقه بند است . هر بلوک کانولوشنی از لایه‌های زیر تشکیل شده است:

- لایه کانولوشن ۲بعدی با فیلتر ۳×۳ و padding=1
- Batch Normalization
- تابع فعال‌سازی ReLU
- MaxPooling با اندازه ۲×۲
- Dropout با نرخ ۰,۲۵

تعداد فیلترها در سه بلوک به ترتیب ۳۲، ۶۴ و ۱۲۸ است . پس از استخراج ویژگی، خروجی وارد بخش طبقه بند می‌شود که شامل سه لایه تمام متصل با ابعاد ۲۵۶، ۱۲۸ و تعداد کلاس‌ها (۱۰) است . در لایه‌های میانی طبقه بند نیز BatchNorm، ReLU و Dropout با نرخ ۰,۵ به کار رفته است .

مدل با بهینه ساز Adam و تابع زیان CrossEntropyLoss آموزش داده شد . نرخ یادگیری اولیه با استفاده از ReduceLROnPlateau تنظیم گردید . پس از آموزش، مدل به دقت نهایی ۹۶,۸۵٪ و پیک ۹۷,۱۷٪ بر روی مجموعه آزمون دست یافت.

۲.۴. سیستم استنتاج فازی

خروجی Softmax مدل CNN به همراه وزن‌های شدت خرابی هر کلاس (severity_weights) برای محاسبه شاخص سلامت (Health Index) استفاده می‌شود . شاخص سلامت به صورت مجموع وزنی احتمالات Softmax تعریف شده است :

$$\mathrm{HI} = \sum\left(probability_i \times severity_weight_i\right)$$

سپس چهار متغیر ورودی به سیستم فازی ممدانی تغذیه می‌شود : Health_Index ، Confidence ، Fault_Severity و HI_Trend . سیستم دو خروجی تولید می‌کند : Risk_Level و Urgency . بر اساس این خروجی‌ها ، وضعیت کلی و پیشنهاد اقدام تعمیراتی تعیین می‌گردد .

۲.۵. شبه‌کد الگوریتم کلی

در ادامه شبه‌کد کامل pipeline از سیگنال تا تصمیم نهایی آورده شده است :

```
Algorithm: Intelligent Bearing Fault Diagnosis Pipeline
Input:  Vibration signal window (32×32), HI_history (optional)
Output: Fault_Type, Health_Index, Risk_Level, State, Recommended_Action


1.  Normalize signal_window (zero-mean, unit-variance)
2.  Convert to tensor and feed to CNN model (BearingCNN)
3.  Compute Softmax probabilities → predicted_class
4.  HI ← Σ (probability_i × severity_weight_i)
5.  Confidence ← max(probability) × 100
6.  Compute HI_Trend from history buffer (if available)
7.  Fault_Severity ← severity_weight[predicted_class]
8.  Feed (HI, Confidence, Fault_Severity, HI_Trend) to Mamdani FIS
```

```
9.  Defuzzify → Risk_Level, Urgency
10. Map Risk_Level & Urgency to State and Recommended_Action
11. Return results to dashboard / real-time API
```

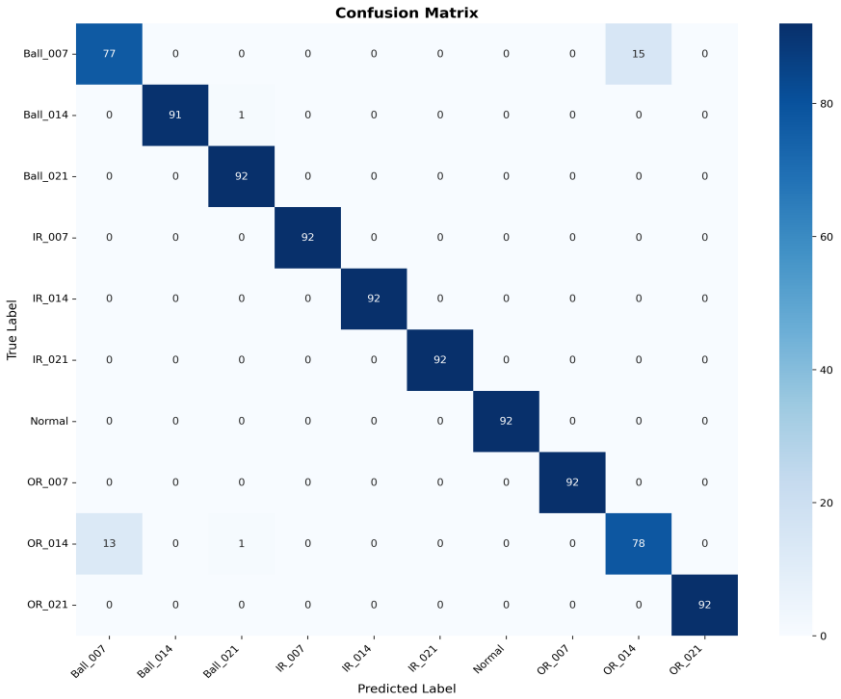
۲.۶. داشبورد و پیش‌بینی بلادرنگ

تابع predict_bearing_fault_real_time امکان دریافت یک پنجره سیگنال جدید و بازگرداندن کامل نتایج (نوع عیب، HI، ریسک، پیشنهاد اقدام) را فراهم می‌کند . داشبورد Streamlit نیز امکان پایش همزمان چند یاتاقان ، نمایش کارت‌های ریسک رنگی ، جستجو و مشاهده جزئیات هر تجهیز را در اختیار کاربر قرار می‌دهد .

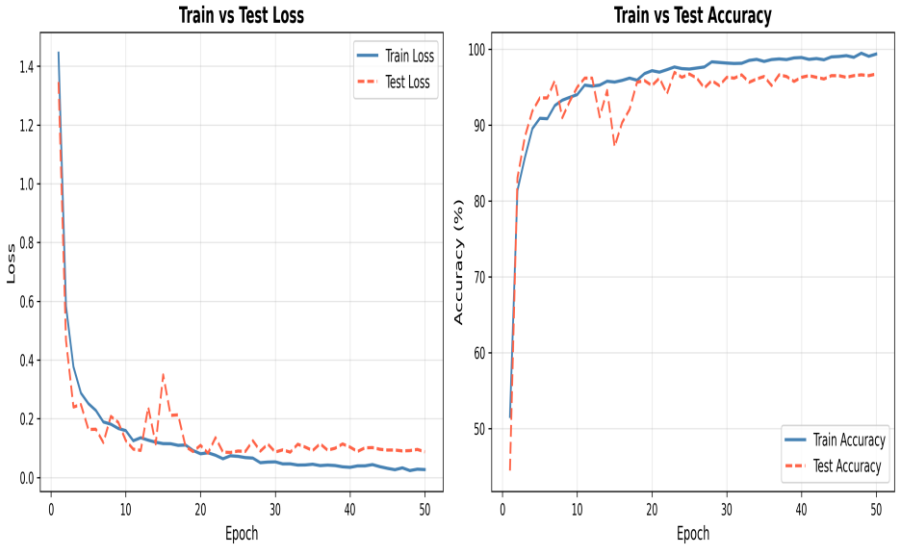
۳. نتایج

۳.۱. عملکرد مدل CNN

مدل نهایی پس از آموزش روی دیتاست CWRU به دقت ۹۶,۸۵٪ بر روی مجموعه آزمون رسید . بهترین دقت مشاهده‌شده در طول آموزش برابر با ۹۷,۱۷٪ بوده است . ماتریس درهم ریختگی و منحنی‌های آموزش/آزمون در ادامه آورده شده‌اند.



شکل ۲ : ماتریس درهم ریختگی مدل CNN روی مجموعه آزمون



شکل ۳ : منحنی‌های دقت و زیان آموزش و آزمون

۳.۲. داشبورد پایش هوشمند

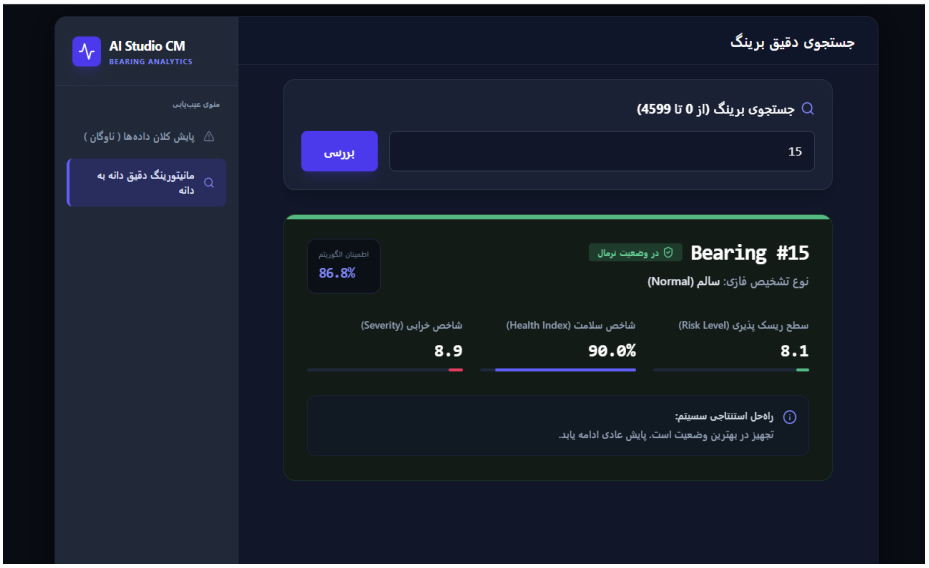
داشبورد طراحی‌شده امکان مشاهده وضعیت چند یاتاقان به صورت همزمان، اولویت‌بندی بر اساس سطح ریسک، جستجوی تجهیز و مشاهده جزئیات هر مورد را فراهم می‌کند . نمونه‌هایی از رابط کاربری در ادامه نمایش داده شده است.



شکل ۴ : نمای کلی داشبورد و کارت‌های ریسک



شکل ۵: قابلیت جستجو و فیلتر در داشبورد



شکل ۶: نمای جزئیات و پیشنهاد اقدام برای یک تجهیز

۳.۳. جمع‌بندی نتایج

نتایج نشان می‌دهد که ترکیب CNN و سیستم فازی می‌تواند علاوه بر تشخیص دقیق نوع خرابی ، شاخص‌های عملیاتی مفیدی برای کارشناسان نگهداری تولید کند . دقت بالای مدل CNN و قابلیت تفسیر خروجی‌های فازی، این سامانه را به ابزاری مناسب برای پایش سلامت تجهیزات در محیط‌های صنعتی تبدیل کرده است .

۴. نتیجه‌گیری و پیشنهادها

در این پروژه، یک سامانه هوشمند هیبریدی برای پایش سلامت یاتاقان‌های صنعتی طراحی و پیاده‌سازی شد . مدل CNN با معماری ساده و سبک به دقت بیش از ۹۶٪ دست یافت و سیستم استنتاج فازی خروجی‌های آن را به شاخص‌های قابل تفسیر (Health Index، Risk Level، Urgency) تبدیل کرد . داشبورد تعاملی نیز امکان استفاده عملی از نتایج را فراهم نمود .

پیشنهادهای توسعه آینده شامل موارد زیر است:

- جمع‌آوری و استفاده از داده‌های واقعی ارتعاشی از تجهیزات مجتمع مس سرچشمه

- توسعه مدل برای سایر تجهیزات (موتور، گیربکس، پمپ و فن)
- افزودن قابلیت پیش‌بینی عمر باقیمانده (RUL)
- یکپارچه سازی با سامانه‌های پایش وضعیت موجود در کارخانه
- استقرار پایلوت در یکی از خطوط تولید